SOFTWARE ENGINEERING MSC

AI στην παραγωγή *λογισμικού.*

Από το ticket έως το merge

Java και CI
Διάλεξη και εργαστήριο 60 λεπτών

01 Ticket

02 Implementation

03 Evaluation

04 Review

05 Merge

ΤΟ ΠΡΟΓΡΑΜΜΑ

Μία αλλαγή. Ολόκληρη η διαδικασία.

0–15′

Απαίτηση

Ticket και context του agent

15–31′

Υλοποίηση

AI κώδικας και πραγματικό CI

31–45′

Αξιολόγηση

Έλεγχοι, μέτρηση και εξήγηση

45–60′

Merge

Review και αυτοματοποίηση

Το setup προηγείται του μαθήματος. Οι δραστηριότητες περιλαμβάνονται στα 60 λεπτά.

ΣΥΖΗΤΗΣΗ ΣΕ ΖΕΥΓΗ · 2 ΛΕΠΤΑ

Τι ακριβώς ζητά το ticket;

«10% έκπτωση για παραγγελίες πάνω από 50 ευρώ»

Το 50.00 περιλαμβάνεται;

Πότε στρογγυλοποιούμε;

Υπάρχει ανώτατη έκπτωση;

Subtotal ≥ 50.00. HALF_UP στην έκπτωση πριν την αφαίρεση. Cap 20.00.

TICKET PRICING-142

Το συμβόλαιο αποδοχής

Επιλεξιμότητα

$$\text{subtotal} \geq 50.00$$

Έκπτωση

$$\min(10\% \times \text{subtotal}, 20.00)$$

Η έκπτωση στρογγυλοποιείται πρώτη

HALF_UP σε δύο δεκαδικά. Έπειτα αφαιρείται.

Η είσοδος έχει σαφή όρια

0 έως 10000. Invalid subtotal προκαλεί IllegalArgumentException.

Το API παραμένει ίδιο

BigDecimal αποτέλεσμα με scale 2. Χωρίς νέες εξαρτήσεις.

Null ή άγνωστο coupon: καμία έκπτωση. strip() και αναγνώριση χωρίς διάκριση πεζών και κεφαλαίων.

Java documentation

ΣΥΜΦΩΝΗΜΕΝΑ EXPECTED RESULTS

Τα παραδείγματα ορίζουν την αποδοχή

SUBTOTAL	COUPON	ΤΕΛΙΚΟ ΠΟΣΟ	ΤΙ ΕΛΕΓΧΕΙ
49.99	STUDENT10	49.99	Κάτω από το όριο
50.00	STUDENT10	**45.00**	Συμπερίληψη ορίου
50.05	STUDENT10	**45.04**	Σειρά στρογγυλοποίησης
500.00	STUDENT10	480.00	Cap έκπτωσης
100.00	OTHER	100.00	Συμπεριφορά χωρίς έκπτωση

CONTEXT

Ο agent χρειάζεται τρόπο να ελέγξει

production-lab/

`ticket.md`

`AGENTS.md`

`docs/feature-map.md`

`src/main/.../PriceCalculator.java`

`ci/evaluate.py`

Τι πρέπει να πετύχει

Απαιτήσεις, examples και δημόσιο API.

Πώς θα το επαληθεύσει

Feature map, ακριβείς εντολές και πραγματικά reports.

Πού επιτρέπεται να δράσει

Απομονωμένο workspace, επιτρεπόμενα paths και όρια.

Η Tan προτείνει κοινά verification tools και ενημερωμένο feature map για κάθε agent.

Lauren Tan / @poteto

Η επανεξήγηση προηγείται της αλλαγής

“Restate the acceptance contract.
Give expected outputs for 49.99, 50.00,
50.05, and 500.00.
Flag ambiguity before changing code."

Αγγλικά για τις τεχνικές οδηγίες. Η ποιότητα επιβεβαιώνεται με evals.

Ίδιο σύντομο instruction: 37 EN / 64 EL tokens με o200k_base. Χωρίς context ή output.

Lauren Tan / @poteto OpenAI token counting

Το AI υλοποιεί.
Εσείς ανοίγετε το PR.

05:00

01 Δώστε το ticket και το σχετικό context.

02 Αλλάξτε μόνο `PriceCalculator.java`.

03 Ανοίξτε PR προς το main του δικού σας fork.

Για checks που δεν εκτέλεσε, ο agent δηλώνει NOT RUN.

GitHub Docs

ΤΟ ΑΡΧΙΚΟ CANDIDATE

Τα υπάρχοντα tests αφήνουν σφάλματα

Legacy tests

3/3

PASS

Πλήρης evaluator

5

failures σε 27 tests

Πραγματικό αποτέλεσμα του lab

```
[PASS] LegacyTest: 3 tests, 0 failures
[FAIL] Full evaluator: 27 tests, 5 failures
```

Ο starter είναι εσκεμμένα λανθασμένος για τη διδασκαλία. Τα στοιχεία προέρχονται από τοπική εκτέλεση.

COUNTEREXAMPLES

Δύο αποκλίσεις από το ίδιο ticket

Το όριο 50.00

```
subtotal.compareTo(
    new BigDecimal("50")) > 0
```

Expected	45.00
Actual	50.00

Η ισότητα αποκλείστηκε.

Το subtotal 50.05

10% έκπτωση	5.005
HALF_UP έκπτωση	5.01
Τελικό ποσό	45.04

Το failure δίνει συγκεκριμένο παράδειγμα για τη διόρθωση. Τα expected values παραμένουν στο συμφωνημένο συμβόλαιο.

Το report οδηγεί τη διόρθωση.

03:00

01 Διαβάστε `result.json` και `build.log`.

02 Συνδέστε ένα failure με απαίτηση του ticket.

03 Δώστε το counterexample στο AI. Ζητήστε νέο fix.

Αν το candidate πέρασε, συγκρίνετε με το baseline report.

ΑΝΕΞΑΡΤΗΤΗ ΑΞΙΟΛΟΓΗΣΗ

Ο evaluator εξετάζει το τελικό artifact

01

Base commit

Tests και build configuration

02

Candidate

Μόνο η Java κλάση

03

Workspace

Νέα, επαναλήψιμη εκτέλεση

04

Report

Αποτέλεσμα και hashes

500 inputs Oracle σε ακέραια cents μέσα σε ένα property test.

Το demo δεν είναι πλήρες sandbox. Σε παραγωγή ο grader και η αναφορά αποτελέσματος χρειάζονται προστατευμένη υποδομή.

Anthropic

Θα απέρριπταν οι έλεγχοι ένα γνωστό λάθος;

5/5

επιλεγμένα σφάλματα απορρίφθηκαν

Η λύση αναφοράς περνά 27/27.

Exclusive threshold	✓ Απορρίφθηκε
Payable-first rounding	✓ Απορρίφθηκε
Missing discount cap	✓ Απορρίφθηκε
Missing normalization	✓ Απορρίφθηκε
Missing validation	✓ Απορρίφθηκε

100% detection σε αυτό το σύνολο. Δεν είναι PIT mutation score ή εκτίμηση της πιθανότητας άγνωστων bugs.

PIT JaCoCo

ΜΕΤΡΗΣΗ

Ο χρόνος review είναι μέρος του κόστους

Ανθρώπινος χρόνος	Ενεργός χρόνος review ανά αποδεκτό PR.
Επαναλήψεις	Πρώτη αποδοχή, rework και εγκαταλειμμένα tasks.
Ποιότητα	Confirmed defects σε σταθερό παράθυρο παρακολούθησης.
Συνολικό κόστος	Όλα τα attempts, CI και συντήρηση του pipeline.

Σύγκριση σε ίδιο task set και budget. Η μείωση του χρόνου review αξιολογείται μαζί με την ποιότητα.

Anthropic Lauren Tan / @poteto

ΕΞΗΓΗΣΗ ΜΕ ΑΡΧΕΣ ASD-STE100

Μια εξήγηση που ελέγχεται γρήγορα

ΑΟΡΙΣΤΟ

«Robust handling όλων των pricing scenarios.»

ΣΥΓΚΕΚΡΙΜΕΝΟ

«Στο 50.05 η έκπτωση γίνεται 5.01. Η τελική τιμή είναι 45.04.»

Μία ιδέα ανά πρόταση. Σταθεροί όροι. Αριθμοί και προϋποθέσεις που διατηρούνται.

Το ASD-STE100 αφορά αγγλικά. Εδώ προσαρμόζουμε αρχές σαφήνειας στα ελληνικά. Η σαφήνεια χρειάζεται τεκμήρια.

Andrej Karpathy ASD-STE100

ΠΕΡΙΓΡΑΦΗ PR ΑΠΟ ΤΟ AI

Το PR συνοψίζει τα τελικά reports

PRICING-142: STUDENT10

Εφαρμόζει το κουπόνι από 50.00. Στρογγυλοποιεί την έκπτωση πριν την αφαίρεση.

Έλεγχοι: 27/27 PASS.
Τεκμήρια: result.json, build.log.
AI review: NOT RUN.

Όριο: εξετάστηκε η Java μέθοδος.
Revert: αναίρεση του commit.

Σύντομο. Συγκεκριμένο. Τεκμηριωμένο.

Τι αλλάζει και γιατί.

Τελικό run και tested SHA.

Ευρήματα, όρια και revert.

Ενδεικτικό PR μετά από successful evaluation. Στη ζωντανή διαδικασία προσθέτουμε το πραγματικό run URL και SHA.

pstack Andrej Karpathy

Review άλλης ομάδας.

01 Ελέγξτε το τρέχον CI και το scope.

02 Διαβάστε την εξήγηση μαζί με τα evidence.

03 Δώστε APPROVE, REQUEST CHANGES ή WAIT.

03:00

Μία αιτιολόγηση με συγκεκριμένο στοιχείο. Αλλάξτε ρόλους.

INSTRUCTOR DEMO · 48–50′ · ΔΩΡΕΑΝ ΣΕ PUBLIC REPO

Το AI review δίνει συγκεκριμένο εύρημα

Το PR αλλάζει τον υπολογισμό

Named constants, με σκόπιμο rounding bug.

CodeRabbit review

+ πραγματικό CI

Location και απαίτηση

Ποια γραμμή αλλάζει τη συμφωνημένη συμπεριφορά;

Counterexample

50.05 → expected 45.04, actual 45.05.

Επαλήθευση

Το finding ελέγχεται με το ticket και το report.

Δείχνουμε πραγματικό rehearsal review. Αν ο reviewer χάσει το bug, το δηλώνουμε. Το fixture δεν είναι AI output.

CodeRabbit GitHub Docs

INSTRUCTOR DEMO · 50–52′

Finding → διόρθωση → νέο run → PR

01

Review

Επαληθευμένο finding

02

Repair

AI fix και δικό μας commit

03

CI

Φρέσκο run και tested SHA

04

AI PR

Σύντομη τελική περιγραφή

Ο άνθρωπος μεταφέρει το finding και κάνει push. Το PR review και τα tests εκτελούνται αυτόματα.

Για τους χρόνους υπηρεσίας χρησιμοποιούμε πραγματικό αποθηκευμένο run. Το πλήρως αυτόνομο repair και το auto-merge είναι συνέχεια.

CodeRabbit

MERGE

Συγχωνεύουμε την αξιολογημένη κατάσταση

01 Required checks και ανεξάρτητο approval.

02 Νέο commit ή αλλαγή στο base απαιτεί επανέλεγχο.

03 Run URL, tested SHA και σαφής τρόπος revert.

```
python ci/evaluate.py --candidate candidate --trusted policy
```

Ο ίδιος evaluator σε GitHub Actions και Jenkins.

Το merge ολοκληρώνει αυτή την αλλαγή. Deployment και monitoring έχουν ξεχωριστή διαδικασία.

GitHub Docs Jenkins documentation

Οι πρακτικές που κρατάμε

01

Verification tools

Κάθε agent μπορεί να ασκήσει την πραγματική συμπεριφορά.

02

Hard constraints

Κανόνες μέσα στον κώδικα, στον compiler και στο CI.

03

Επιθεωρήσιμα artifacts

Evidence που διαβάζεται χωρίς replay όλου του run.

04

Συντήρηση του pipeline

Κάθε επαναλαμβανόμενο σφάλμα γίνεται μόνιμος έλεγχος.

Σύνθεση από πρωτογενή posts της Tan. Η εφαρμογή στη Java και στο lab είναι διδακτική πρόταση.

Lauren Tan / @poteto

ΠΕΡΑΙΤΕΡΩ ΑΥΤΟΜΑΤΟΠΟΙΗΣΗ

Το lab μπορεί να γίνει συνεχής κύκλος

01 **Ticket**

Συμφωνημένα κριτήρια

02 **Agent + CI**

Κώδικας και tests

03 **AI review**

Συγκεκριμένα findings

04 **Repair**

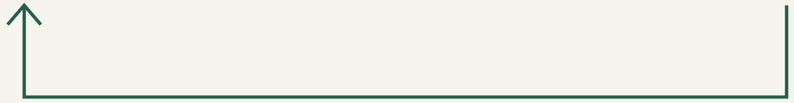
Διόρθωση και νέο run

05 **AI PR**

Σύνοψη τελικών reports

06 **Merge**

Policy και monitoring



Εύρημα που χρειάζεται διόρθωση: νέο run

Το demo δείχνει PR review και CI. Η αυτόματη σύνδεση με repair και το auto-merge είναι συνέχεια.

Lauren Tan / @poteto pstack

Η ανθρώπινη προσοχή εστιάζει στις εξαιρέσεις

ΓΝΩΣΤΕΣ ΚΑΤΗΓΟΡΙΕΣ ΑΛΛΑΓΩΝ

Σύντομος έλεγχος των evidence.

Σταδιακή εφαρμογή auto-merge όταν το ιστορικό και η policy το στηρίζουν.

ΕΞΩ ΑΠΟ ΤΗΝ POLICY

Στοχευμένο ανθρώπινο review.

Νέος κίνδυνος, ασάφεια, ανεπίλυτο finding ή ανεπαρκής αξιολόγηση.

Η Tan περιγράφει agents που κάνουν merge και δικό της review στο main αργότερα. Αυτό αφορά το δικό της περιβάλλον.

Lauren Tan / @poteto

ΤΟ ΤΕΛΙΚΟ TAKEAWAY

Η βασική δουλειά μεταφέρεται στο *αξιόπιστο pipeline.*

Ο engineer κατασκευάζει και συντηρεί το σύστημα που παράγει, ελέγχει και παραδίδει αποδεκτές αλλαγές.

Tests AI reviews Σύντομα PRs Μετρημένη ποιότητα

EXIT TICKET · 2 ΛΕΠΤΑ

Τι θα αυτοματοποιούσατε στη συνέχεια;

01 Ποιο failure mode θα κάνατε μόνιμο check;

02 Ποιο μέρος του review μπορεί να αναλάβει το pipeline;

03 Ποια μέτρηση θα δικαιολογούσε μεγαλύτερη αυτονομία;

Lauren Tan / @poteto

Loops You Can Trust

24 Ιουνίου 2026

Organic architecture

18 Ιουλίου 2026

Verification και feature maps

30 Ιουλίου 2026

Agentic review και repair

8 Αυγούστου 2026

Agents που κάνουν merge

11 Αυγούστου 2026

O gardener του codebase

20 Αυγούστου 2026

Constraints και engineering

5 Οκτωβρίου 2026

Πηγές αξιολόγησης και εξήγησης

Agent evaluations

Anthropic

Σαφήνεια output και ASD-STE100

Karpathy

Required checks και approvals

GitHub

Pipeline syntax

Jenkins

BigDecimal

Java 17

Mutation testing

PIT

Coverage checks

JaCoCo

Simplified Technical English

ASD-STE100

Anthropic Andrej Karpathy

΄Ενα review με ελέγξιμα ευρήματα

Read the ticket, final diff, and actual CI reports in a fresh context.

For each material finding: code location, violated requirement, specific counterexample, and evidence.

Label unverified hypotheses. Check evaluation gaps and whether the PR description matches the final reports.

Νέο context βοηθά τη χωριστή εξέταση. Η ορθότητα του reviewer χρειάζεται δικά της evals και ανθρώπινα ελεγμένα παραδείγματα.